Mercedes Global Sales 2020–2025

Datenquelle, Ziel der Analyse, Forschungsfragen und Zielvariable

Der Datensatz stammt von Kaggle:

Dhrubang Talukdar (2025) Mercedes Global Car Sales (2020–2025)

https://www.kaggle.com/datasets/dhrubangtalukdar/mercedes-global-car-sales-2020-2025

Ziel der Analyse:

Untersuchung der Einflussfaktoren auf den Basispreis (USD) von Mercedes-Benz Fahrzeugen.

Forschungsfragen:

1. Welche Merkmale beeinflussen den Basispreis signifikant?
2. Wie gut lässt sich der Basispreis anhand technischer und struktureller Merkmale vorhersagen?

Zielvariable:

Base Price (USD)

Setup

Imports, Pfade und Helper

In [13]:
```
from pathlib import Path
from pathlib import PurePath
import sys
import re
```

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.ticker as mticker
import seaborn as sns
from ydata_profiling import ProfileReport

# Pfade
BASE_DIR = Path.cwd()

INPUT_RAW = BASE_DIR / "input" / "raw"
INPUT_PROCESSED = BASE_DIR / "input" / "processed"

OUTPUT_DIR = BASE_DIR / "output"
OUTPUT_FIGURES = OUTPUT_DIR / "figures"

FIG_EDA = OUTPUT_FIGURES / "eda"
FIG_MODELING = OUTPUT_FIGURES / "modeling"
DOCS_DIR = BASE_DIR / "docs"

# Ordner anlegen
for p in [INPUT_PROCESSED, OUTPUT_FIGURES, FIG_EDA, FIG_MODELING, DOCS_DIR]:
    p.mkdir(parents=True, exist_ok=True)

DATA_FILE = INPUT_RAW / "mercedes_benz_sales_2020_2025.csv"


# Helper
def _slugify(text: str) -> str:
    text = (text or "").strip()
    text = re.sub(r"[^\w\s-]", "", text)
    return text if text else "Plot"

def _next_plot_number(fig_dir: Path) -> int:
    pattern = re.compile(r"^(\d{2,})_.*\.png$", re.IGNORECASE)
    nums = []
    for p in fig_dir.glob("*.png"):
        m = pattern.match(p.name)
        if m:
            nums.append(int(m.group(1)))
    return (max(nums) + 1) if nums else 1
```

```
plot_counter_eda = _next_plot_number(FIG_EDA)

def save_current_plot_eda(dpi: int = 300):

    global plot_counter_eda

    fig = plt.gcf()
    if fig is None or len(fig.axes) == 0:
        print("Kein Plot zum Speichern")
        return

    title = plt.gca().get_title() or "plot"
    filename = f"{plot_counter_eda:02d} {_slugify(title)}.png"
    filepath = FIG_EDA / filename

    if filepath.exists():
        project_name = BASE_DIR.name
        relative_path = filepath.relative_to(BASE_DIR)
        full_display_path = PurePath(project_name) / relative_path
        print(f"Übersprungen: {full_display_path}")
    else:
        fig.tight_layout()
        fig.savefig(filepath, dpi=dpi, bbox_inches="tight")

        project_name = BASE_DIR.name
        relative_path = filepath.relative_to(BASE_DIR)
        full_display_path = PurePath(project_name) / relative_path
        print(f"Gespeichert: {full_display_path}")

    plot_counter_eda += 1
```

Profiling Report

In [14]:
```
df = pd.read_csv(DATA_FILE)

report_path = DOCS_DIR / "Mercedes_Sales_Profiling.html"

if report_path.exists():
    print("Profiling Report existiert bereits unter: docs")
    print("Erstellung übersprungen")
```

```
else:
    print("Erstelle Profiling Report...")

    profile = ProfileReport(
        df,
        title="Mercedes-Benz Global Sales – Profiling Report",
        explorative=True,
        minimal=True,
        progress_bar=True
    )

    profile.to_file(report_path)

    print("Profiling Report gespeichert")
```

```
Erstelle Profiling Report...
Summarize dataset:   0%|          | 0/5 [00:00<?, ?it/s]
100%|██████████| 9/9 [00:01<00:00,  6.16it/s]
Generate report structure:   0%|          | 0/1 [00:00<?, ?it/s]
Render HTML:   0%|          | 0/1 [00:00<?, ?it/s]
Export report to file:   0%|          | 0/1 [00:00<?, ?it/s]
Profiling Report gespeichert
```

Datenqualität

In [15]:
```
# Daten laden
df = pd.read_csv(DATA_FILE)
print("Form:", df.shape)

# Struktur und Datentyp
df.info()
df.head()
```

```
Form: (12132666, 9)
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 12132666 entries, 0 to 12132665
Data columns (total 9 columns):
 #   Column            Dtype
---  ------            -----
 0   Model             object
 1   Year              int64
 2   Region            object
 3   Color             object
 4   Fuel Type         object
 5   Base Price (USD)  int64
 6   Horsepower        int64
 7   Sales Volume      int64
 8   Turbo             object
dtypes: int64(4), object(5)
memory usage: 833.1+ MB
```

Out[15]:

	Model	Year	Region	Color	Fuel Type	Base Price (USD)	Horsepower	Sales Volume	Turbo
0	A-Class	2020	Global	Yellow	Diesel	41265	252	1	Yes
1	A-Class	2020	Global	Black	Petrol	51023	249	1	No
2	A-Class	2020	Global	Grey	Petrol	72819	341	1	Yes
3	A-Class	2020	Global	Black	Petrol	62480	385	1	Yes
4	A-Class	2020	Global	White	Petrol	35189	337	1	Yes

- 12.132.666 Beobachtungen und 9 Variablen
- 4 numerische und 5 kategoriale Variablen
- Struktur konsistent und plausibel
- Keine offensichtlichen Format- oder Typfehler
- Hoher Speicherbedarf (~833 MB) -> relevant für Performance

Fehlende Werte prüfen

In [16]:
```
df.isna().sum()
```

Out[16]:
```
Model              0
Year               0
Region             0
Color              0
Fuel Type          0
Base Price (USD)   0
Horsepower         0
Sales Volume       0
Turbo              0
dtype: int64
```

- Keine fehlenden Werte in allen 9 Variablen
- Keine Imputation erforderlich
- Keine Reduktion der Stichprobengröße notwendig
- Datensatz vollständig für weitere Analyse nutzbar

Duplikate prüfen

In [17]:
```
# Übersicht
n_duplicates = df.duplicated().sum()
n_total = len(df)
percentage = (n_duplicates / n_total) * 100

dup_summary = pd.DataFrame({
    "Kennzahl": ["Gesamtbeobachtungen", "Duplikate", "Anteil (%)"],
    "Wert": [
        f"{n_total:,.0f}".replace(",", "."),
        f"{n_duplicates:,.0f}".replace(",", "."),
        f"{percentage:.4f}"
    ]
})

dup_summary
```

Out[17]:

	Kennzahl	Wert
0	Gesamtbeobachtungen	12.132.666
1	Duplikate	3.153
2	Anteil (%)	0.0260

- 3.153 doppelte Beobachtungen identifiziert
- Anteil sehr gering (~0,026 %)
- Für die spätere Modellierung bereinigen

In [18]:

```
# Duplikate entfernen
n_before = len(df)

df = df.drop_duplicates()

n_after = len(df)
removed = n_before - n_after

print(f"Entfernte Duplikate: {removed:,}".replace(",", "."))
print(f"Neue Anzahl Beobachtungen: {n_after:,}".replace(",", "."))
```

```
Entfernte Duplikate: 3.153
Neue Anzahl Beobachtungen: 12.129.513
```

- 3.153 Duplikate entfernt
- Datensatz strukturell bereinigt
- Keine künstliche Mehrfachgewichtung einzelner Konfigurationen
- Grundlage für unverzerrte Modellschätzung geschaffen

Explorative Datenanalyse (EDA)

Univariaten Analyse - Base Price (USD)

In [19]:
```
# Übersicht
df["Base Price (USD)"].describe()
```

Out[19]:
```
count    1.212951e+07
mean     1.042226e+05
std      6.783929e+04
min      3.500000e+04
25%      6.346400e+04
50%      8.357400e+04
75%      1.199280e+05
max      4.112460e+05
Name: Base Price (USD), dtype: float64
```

In [20]:
```
# Quantilbereich
q1 = df["Base Price (USD)"].quantile(0.25)
median = df["Base Price (USD)"].quantile(0.5)
q3 = df["Base Price (USD)"].quantile(0.75)

plt.figure(figsize=(10,6))

sns.histplot(df["Base Price (USD)"], bins=50, color="#2E86C1")

plt.axvline(q1, color="orange", linestyle="--", label="Q1 (25%)")
plt.axvline(median, color="red", linestyle="--", label="Median")
plt.axvline(q3, color="green", linestyle="--", label="Q3 (75%)")

plt.legend()
plt.title("Verteilung mit Quantilbereichen")
plt.xlabel("Basispreis (USD)")

save_current_plot_eda()

df["Base Price (USD)"].quantile([0.25, 0.5, 0.75])
plt.show()
```

```
Gespeichert: Mercedes_Global_Sales\output\figures\eda\01 Verteilung mit Quantilbereichen.png
```

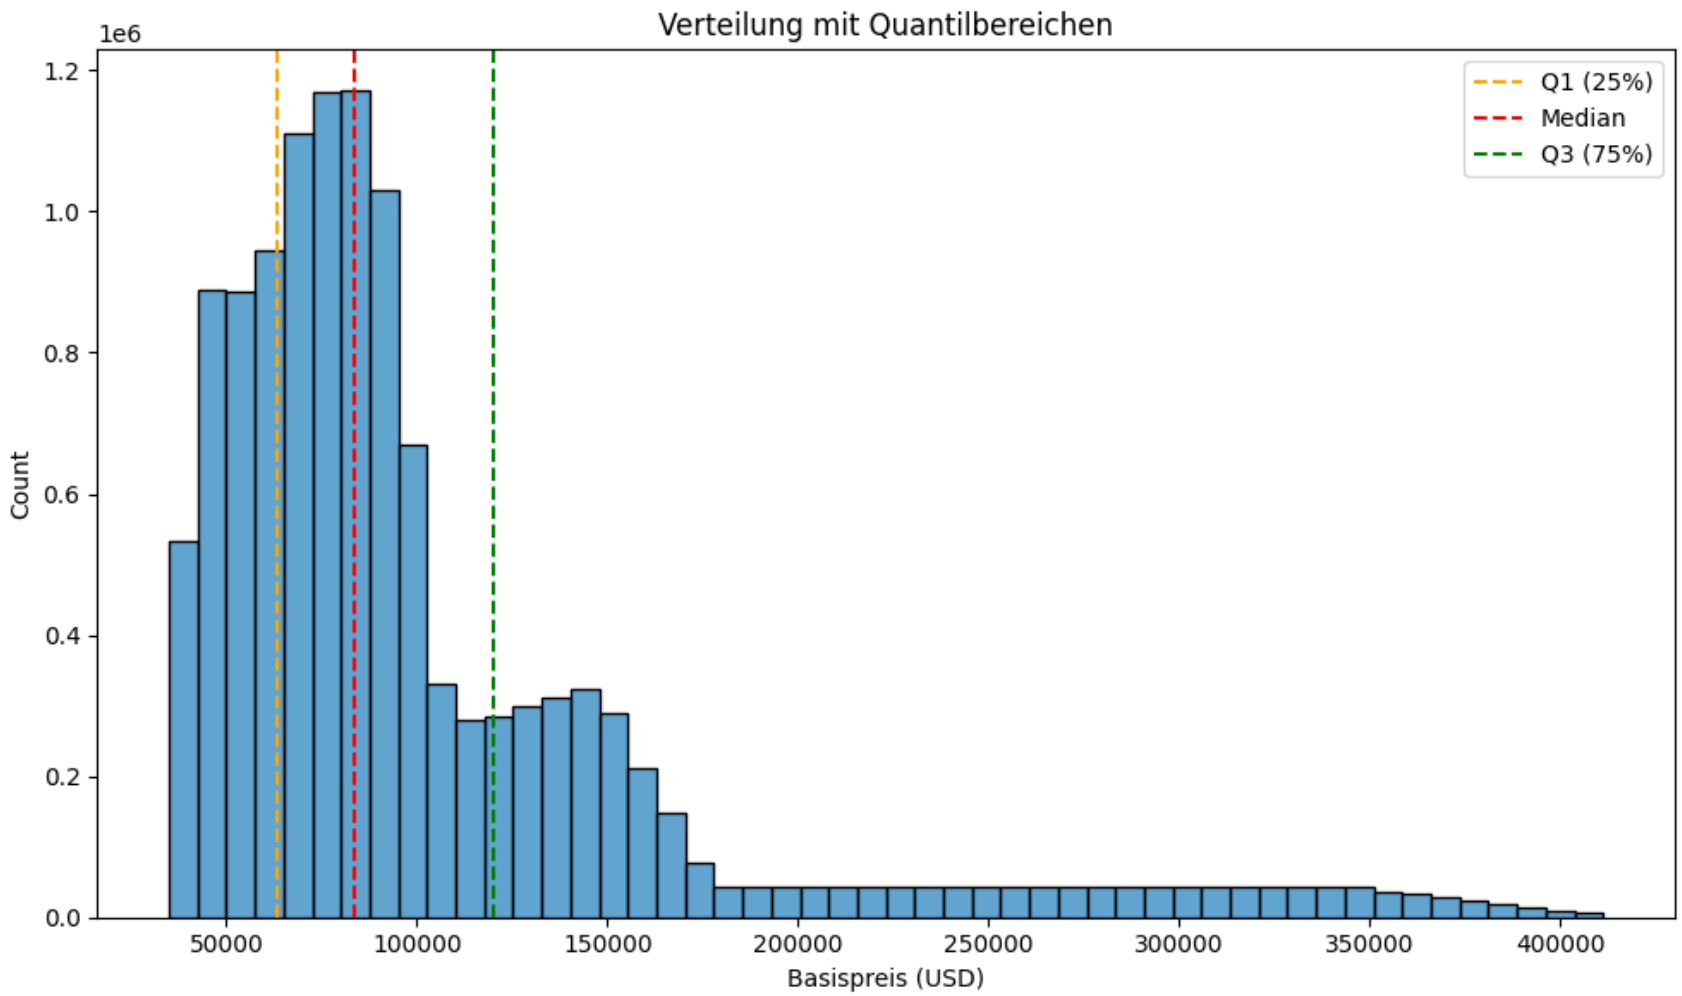

- 25 %-Quantil bei ca. 63.464 USD
- Median bei ca. 83.574 USD
- 75 %-Quantil bei ca. 119.928 USD
- 50 % der Fahrzeuge liegen im Interquartilsbereich von ca. 63.000–120.000 USD
- Langer rechter Verteilungsschwanz bis über 400.000 USD
- Hochpreisige Modelle erhöhen den arithmetischen Mittelwert

Univariate Analyse – numerische Variablen

In [21]:
```
numeric_cols = df.select_dtypes(include="int64").columns

df[numeric_cols].describe()
```

Out[21]:

	Year	Base Price (USD)	Horsepower	Sales Volume
count	1.212951e+07	1.212951e+07	1.212951e+07	12129513.0
mean	2.022548e+03	1.042226e+05	3.674664e+02	1.0
std	1.658897e+00	6.783929e+04	1.195476e+02	0.0
min	2.020000e+03	3.500000e+04	1.500000e+02	1.0
25%	2.021000e+03	6.346400e+04	2.750000e+02	1.0
50%	2.023000e+03	8.357400e+04	3.580000e+02	1.0
75%	2.024000e+03	1.199280e+05	4.440000e+02	1.0
max	2.025000e+03	4.112460e+05	8.310000e+02	1.0

In [22]:
```
plt.figure(figsize=(8,6))

sns.scatterplot(
    x=df["Horsepower"],
    y=df["Base Price (USD)"],
    alpha=0.2
)

plt.title("Base Price vs. Horsepower (PS)")
plt.xlabel("Horsepower (PS)")
plt.ylabel("Base Price (USD)")

save_current_plot_eda()

plt.show()
```

```
Gespeichert: Mercedes_Global_Sales\output\figures\eda\02 Base Price vs Horsepower PS.png
```

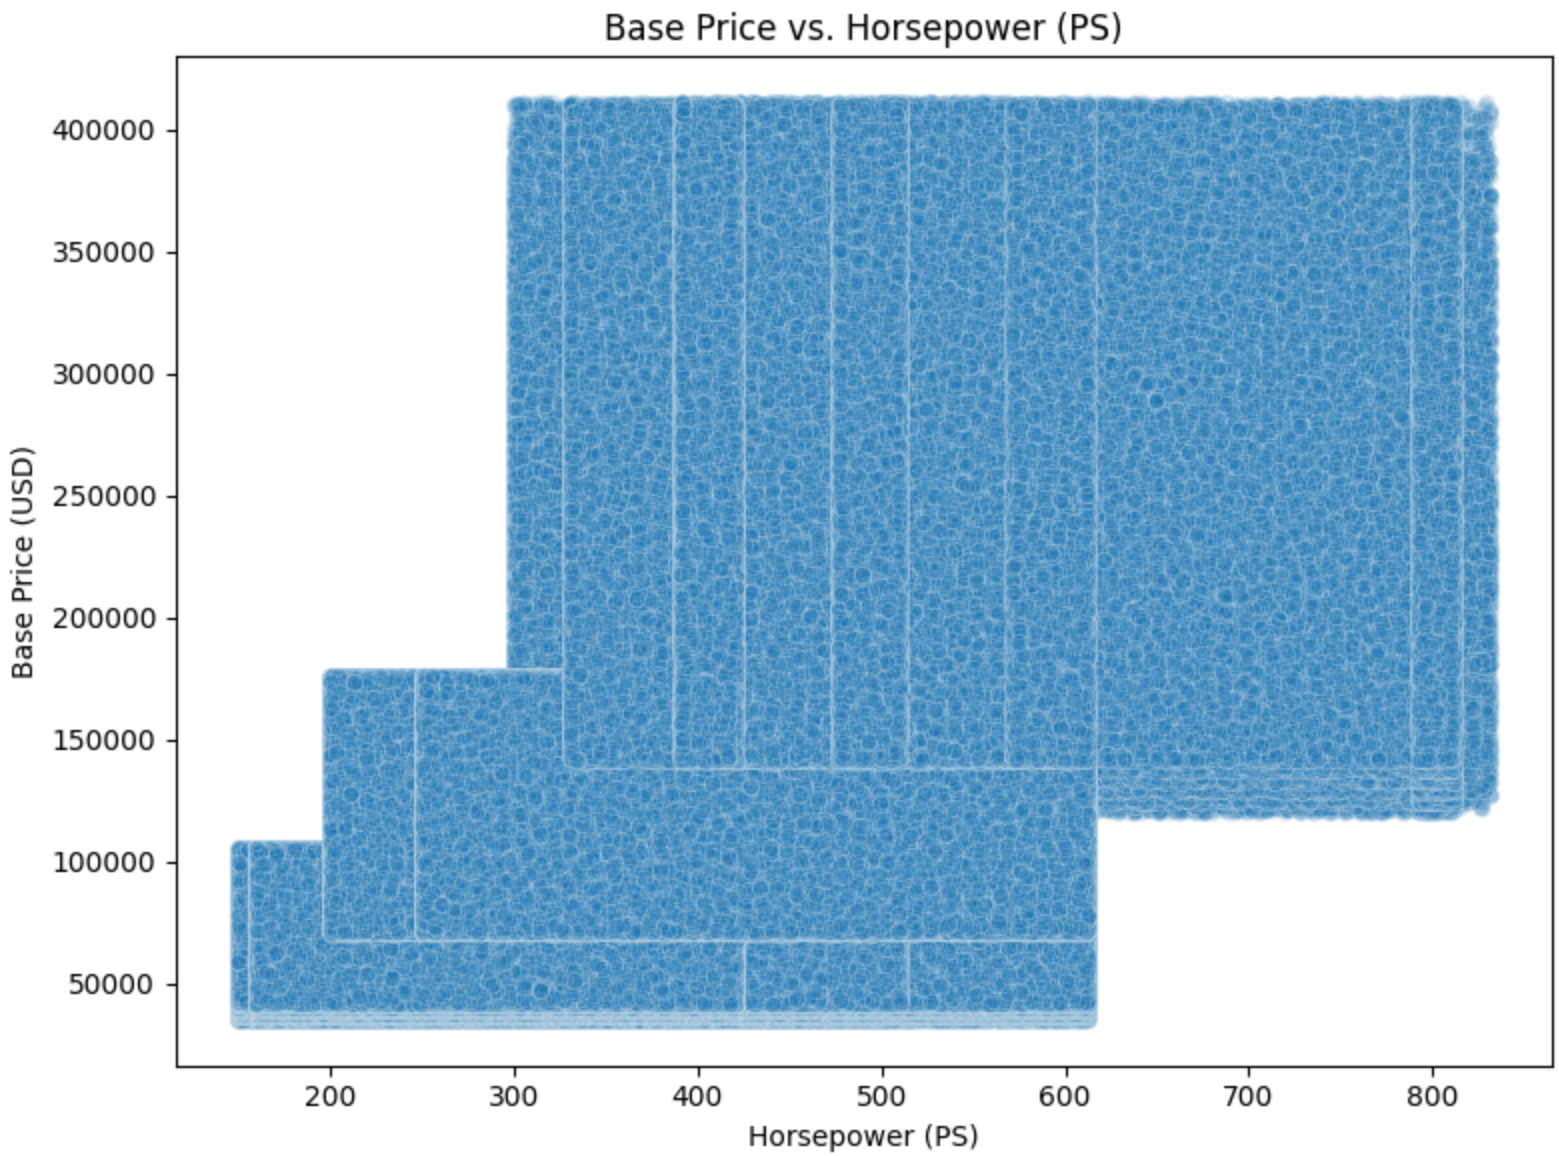

- mit über 12 Mio. Beobachtungen unübersichtlich
- keine erkennbare Struktur
- Overplotting

In [23]:
```
grouped = df.groupby("Horsepower")["Base Price (USD)"].mean()

plt.figure(figsize=(8,6))
plt.plot(grouped.index, grouped.values)
plt.title("Durchschnittspreis je Horsepower (PS)")
plt.xlabel("Horsepower (PS)")
plt.ylabel("Durchschnittlicher Preis")

save_current_plot_eda()

plt.show()
```

```
Gespeichert: Mercedes_Global_Sales\output\figures\eda\03 Durchschnittspreis je Horsepower PS.png
```

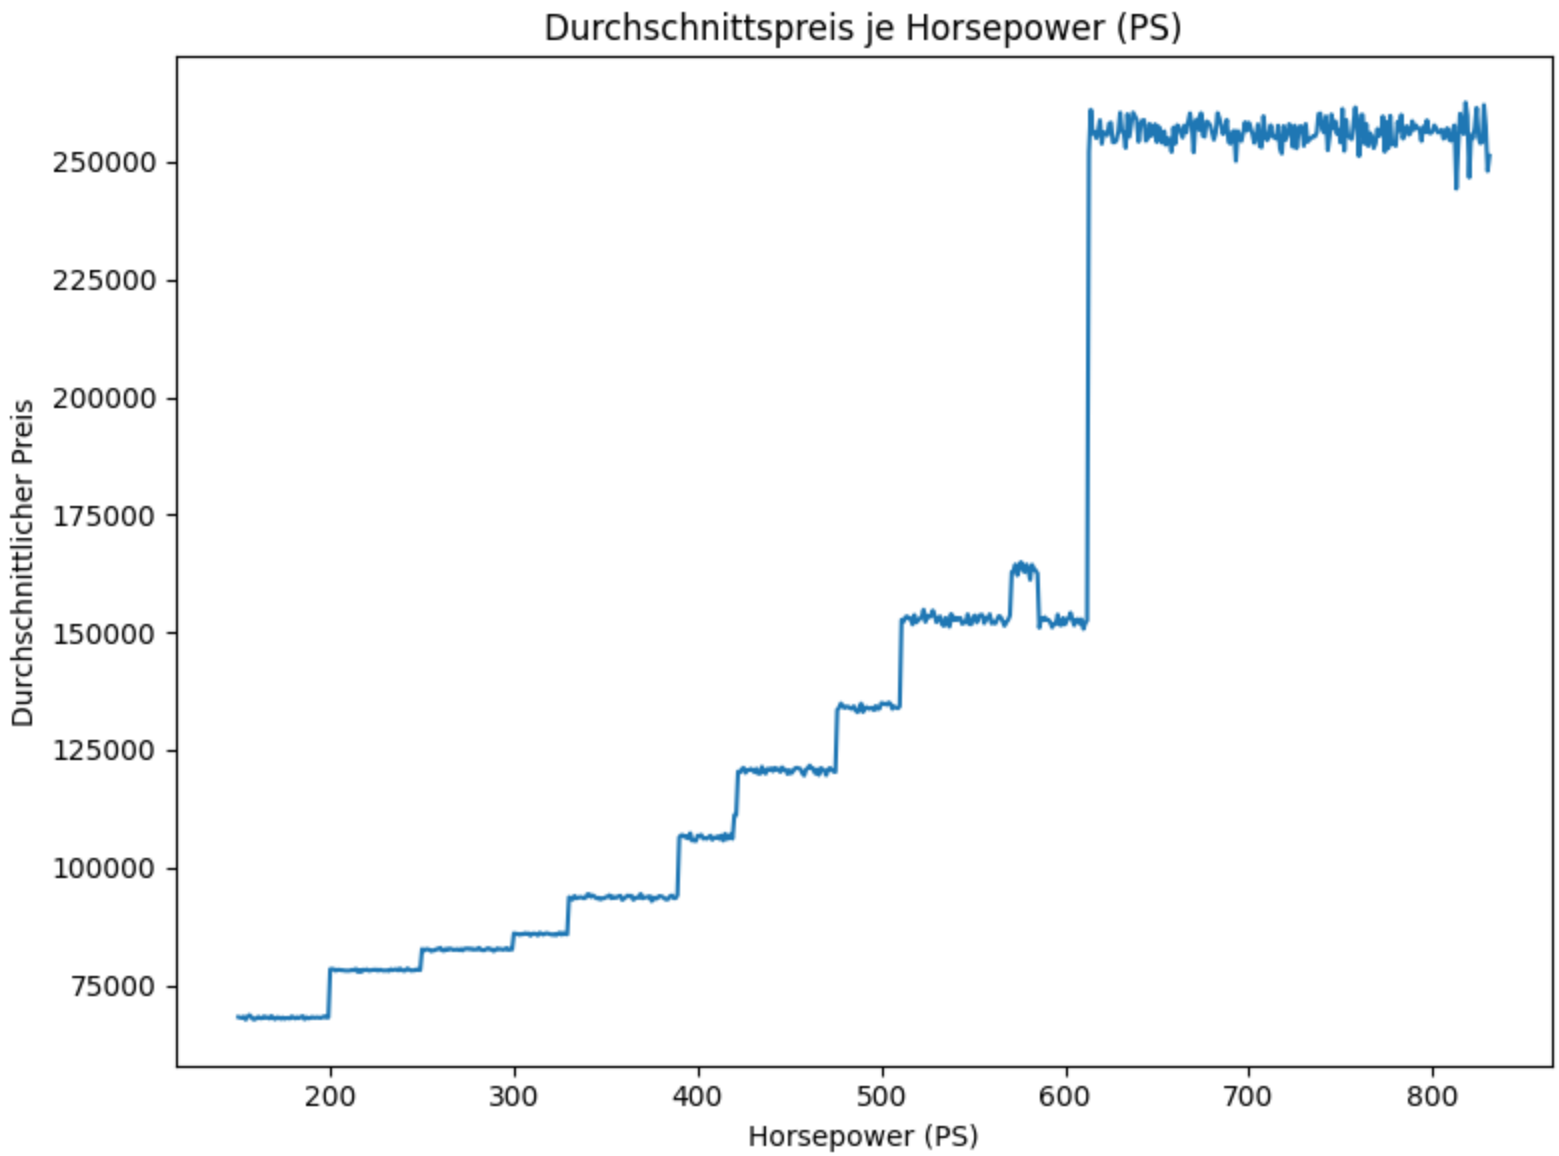

- Deutlicher positiver Zusammenhang zwischen PS und Preis
- Durchschnittspreis steigt stufenartig mit zunehmender Leistung
- Preisbildung erfolgt offenbar segmentbasiert (Modellklassen)
- Ab ca. 600 PS klarer Übergang ins Hochpreissegment

- Zusammenhang nicht strikt linear, sondern strukturell diskret

Univariate Analyse – Horsepower

In [24]:
```
plt.figure(figsize=(8,5))

sns.histplot(
    df["Horsepower"],
    bins=40,
    kde=True
)

plt.title("Verteilung Horsepower (PS)")
plt.xlabel("Horsepower (PS)")
plt.ylabel("Häufigkeit")

save_current_plot_eda()

plt.show()
```

```
Gespeichert: Mercedes_Global_Sales\output\figures\eda\04 Verteilung Horsepower PS.png
```

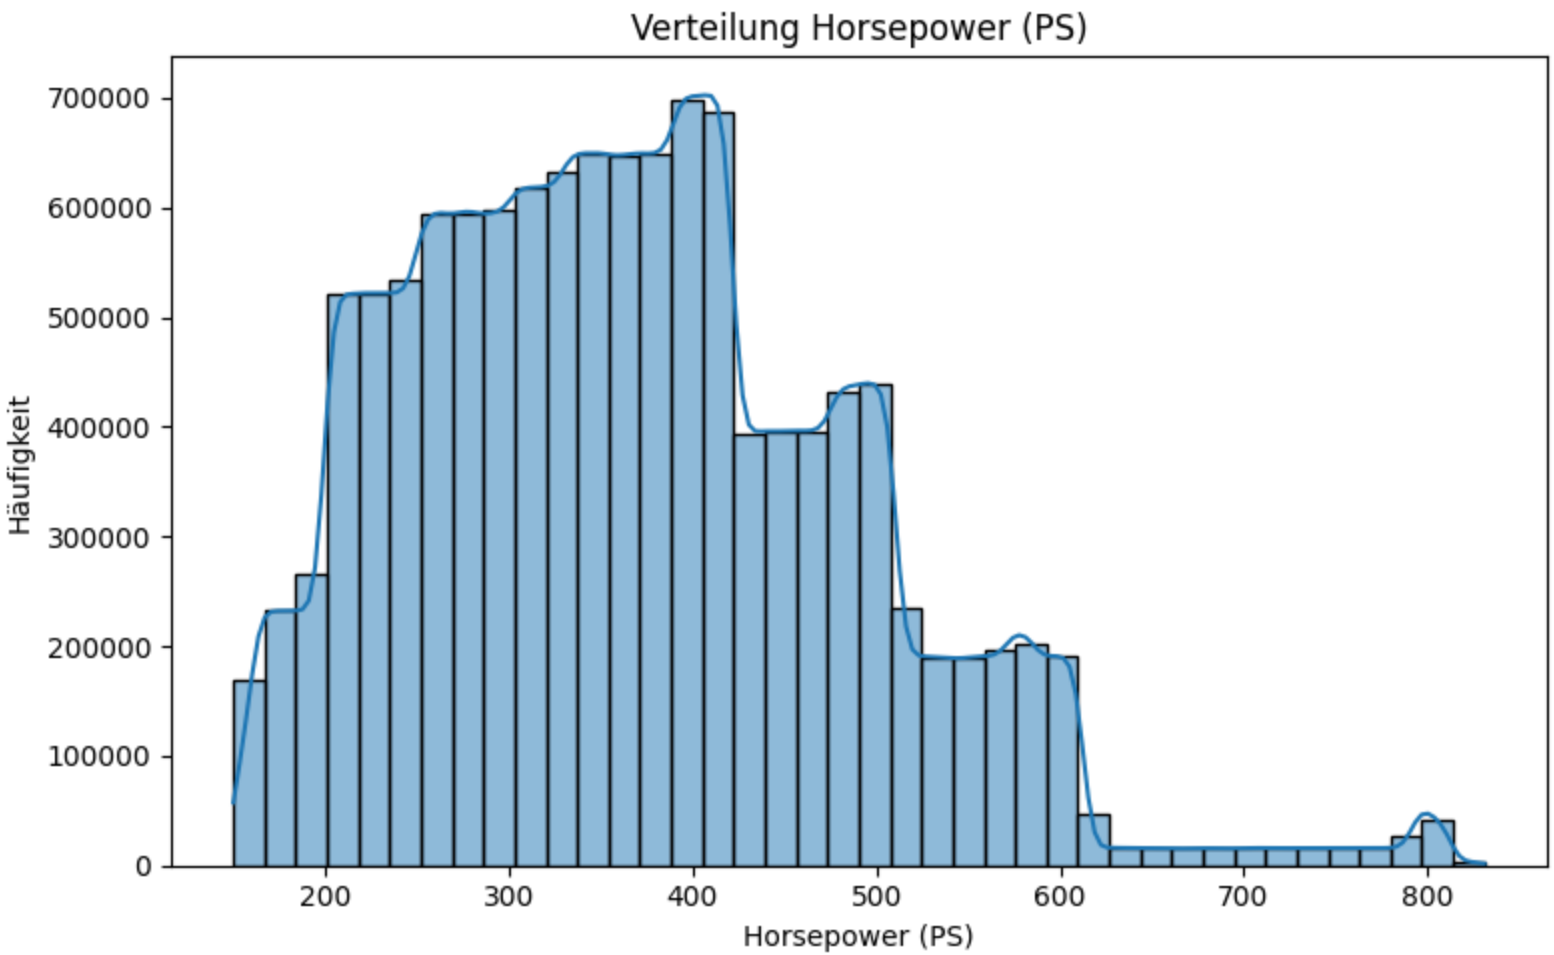

- Breite Streuung von ca. 150 bis über 800 PS
- Mehrheit der Fahrzeuge im mittleren Leistungssegment
- Leicht rechtsschiefe Verteilung
- Gute Varianz -> potenziell starker Preistreiber

Bivariate Analyse

Base Price vs. Model

In [25]:
```
top_models = df["Model"].value_counts().head(10).index

plt.figure(figsize=(10,6))

sns.boxplot(
    x="Model",
    y="Base Price (USD)",
    data=df[df["Model"].isin(top_models)]
)

plt.xticks(rotation=45)
plt.title("Base Price nach Modell (Top 10)")
plt.xlabel("Modell")
plt.ylabel("Base Price (USD)")

save_current_plot_eda()

plt.show()
```

```
Gespeichert: Mercedes_Global_Sales\output\figures\eda\05 Base Price nach Modell Top 10.png
```

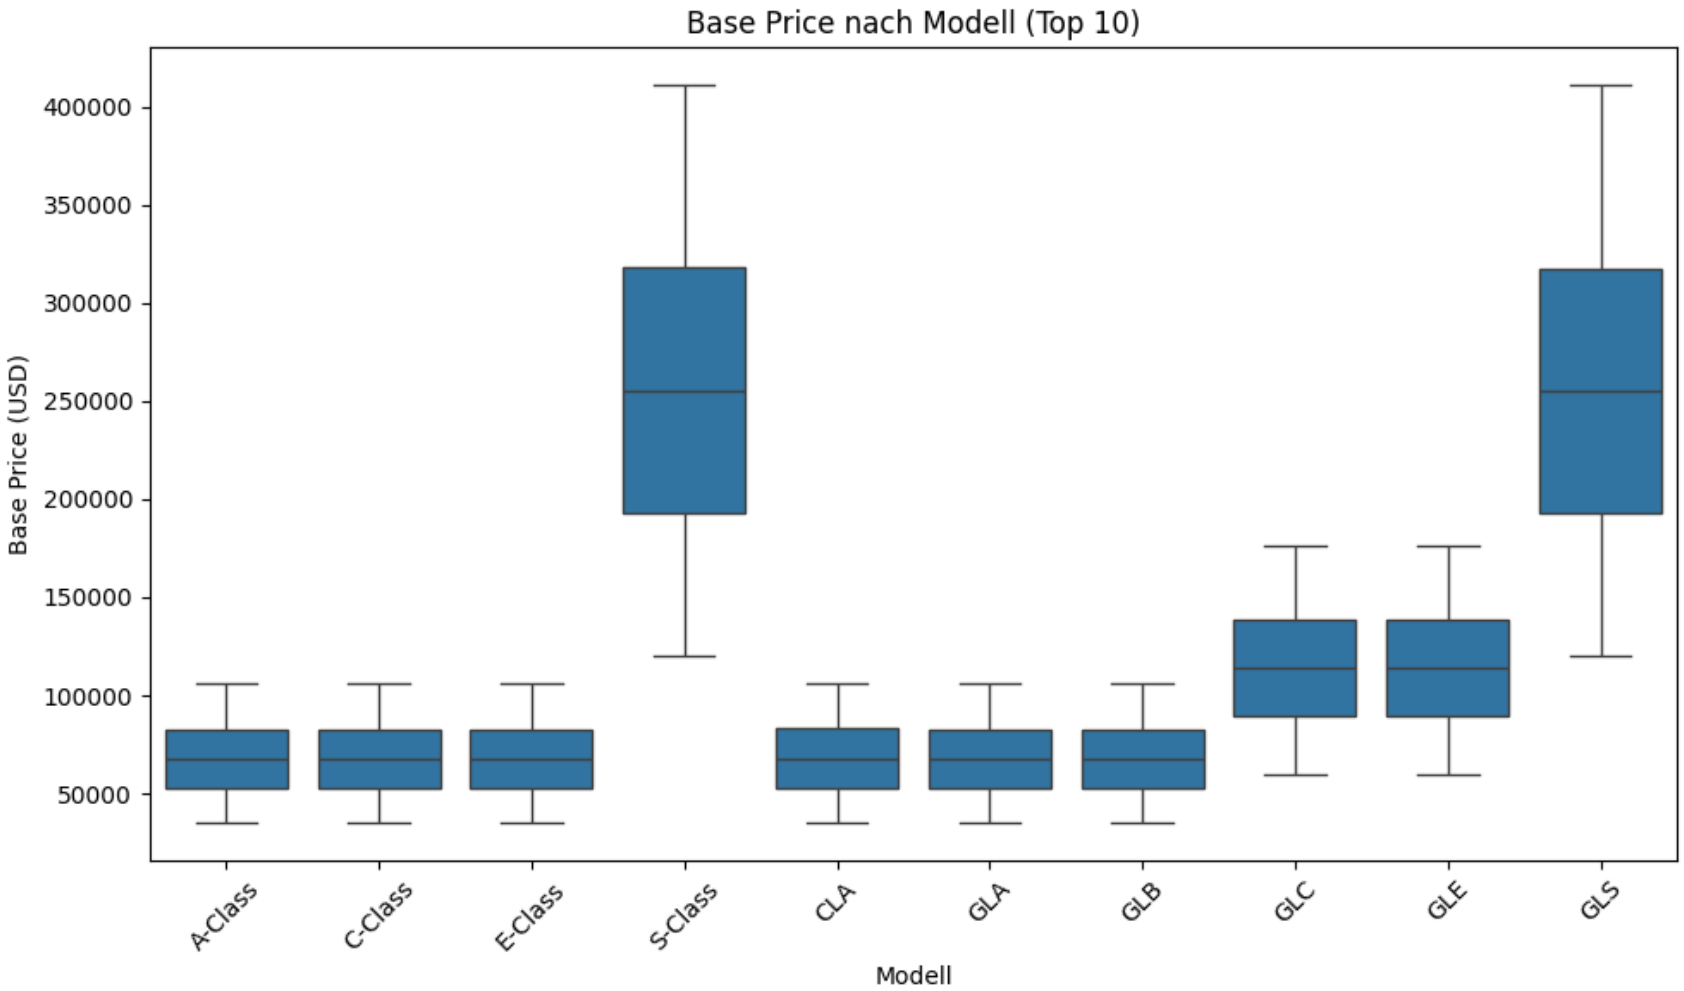

- Deutliche Preisunterschiede zwischen Modellklassen
- S-Klasse / GLS im oberen Preissegment
- GLC und GLE im gehobenen SUV-Segment
- A-, C-, E- und kompakte Modelle im Kernpreissegment
- Modellklasse wirkt als struktureller Preistreiber

Base Price vs. Fuel Type

In [26]:
```
median_fuel = df.groupby("Fuel Type")["Base Price (USD)"].median().sort_values()

plt.figure(figsize=(6,4))
ax = median_fuel.plot(kind="bar")

plt.title("Preis je Fuel Type (Median)")
plt.ylabel("Base Price (USD)")
plt.xlabel("Fuel Type")

plt.ylim(0, 100000)   # <-- Achse bis 100.000 USD

# Werte über Balken
for i, value in enumerate(median_fuel):
    ax.text(
        i,
        value + 1500,
        f"{value:,.0f}".replace(",", "."),
        ha="center",
        fontweight="bold"
    )

plt.tight_layout()

save_current_plot_eda()

plt.show()
```

```
Gespeichert: Mercedes_Global_Sales\output\figures\eda\06 Preis je Fuel Type Median.png
```

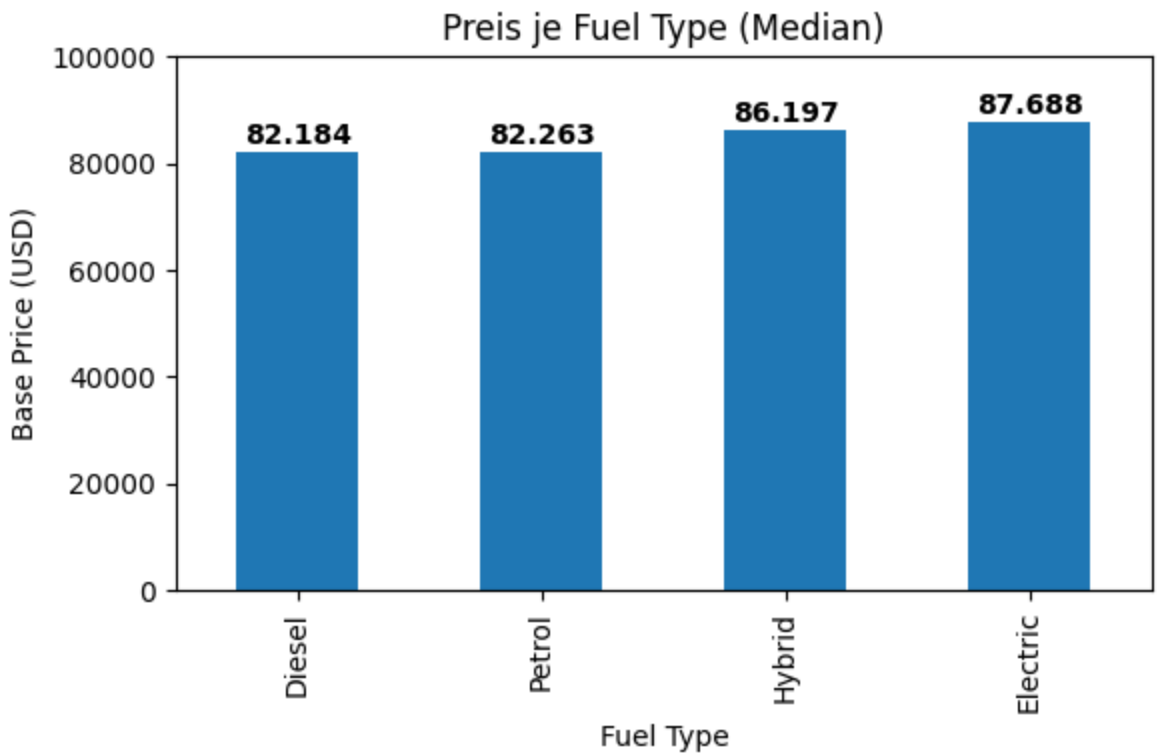

- Diesel und Petrol (Benzin) nahezu identisches Preisniveau
- Hybrid und Electric leicht höherer Medianpreis
- Differenz zwischen niedrigstem und höchstem Median ca. 5.500 USD
- Einfluss des Fuel Type moderat und deutlich geringer als der Modelleffekt
- Fuel Type wirkt als sekundärer Preistreiber

Export

In [27]:
```
# Processed Dataset Export
PROCESSED_DIR = BASE_DIR / "input" / "processed"
PROCESSED_DIR.mkdir(parents=True, exist_ok=True)

processed_file = PROCESSED_DIR / "mercedes_sales_processed.csv"
```

```python
if processed_file.exists():
    print(f"Übersprungen – Datei existiert bereits: {processed_file.name}")
else:
    df_processed = df.drop_duplicates().copy()

    if "Sales Volume" in df_processed.columns and df_processed["Sales Volume"].nunique() == 1:
        df_processed = df_processed.drop(columns=["Sales Volume"])
        print("Info: 'Sales Volume' entfernt (keine Varianz).")

    df_processed.to_csv(processed_file, index=False, encoding="utf-8")
    print(f"Gespeichert: {processed_file.relative_to(BASE_DIR)}")
    print(f"Form processed: {df_processed.shape}")
```

```
Info: 'Sales Volume' entfernt (keine Varianz).
Gespeichert: input\processed\mercedes_sales_processed.csv
Form processed: (12129513, 8)
```

- Duplikate entfernt
- Spalten ohne Varianz entfernt
- Keine Transformation oder Skalierung durchgeführt
- Struktur für Modellierung vorbereitet