Regressionsbaum

Ziel des Regressionsbaums

Der Regressionsbaum untersucht den Basispreis in USD.
Er zeigt klar, welche Merkmale den Fahrzeugpreis besonders prägen.
Dabei wird sichtbar, wie sich verschiedene Preisbereiche entwickeln.
So wird die Preisstruktur des Modells nachvollziehbar dargestellt.

Setup

Imports, Pfade und Helper

In [1]:
```
%matplotlib inline

from pathlib import Path
from pathlib import PurePath
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import re

from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeRegressor, plot_tree
from sklearn.metrics import r2_score, mean_squared_error, mean_absolute_error
from sklearn.model_selection import cross_val_score

# Pfade definieren und Ordnerstruktur für Modellierungs-Plots anlegen
ROOT = Path.cwd()
BASE_DIR = ROOT

INPUT_RAW = ROOT / "input" / "raw"
INPUT_PROCESSED = ROOT / "input" / "processed"
```

```python
OUT = ROOT / "output"
FIG_DIR = OUT / "figures"

FIG_TREE = FIG_DIR / "modeling" / "regressionsbaum"
FIG_TREE.mkdir(parents=True, exist_ok=True)

for p in [INPUT_RAW, INPUT_PROCESSED, FIG_DIR]:
    p.mkdir(parents=True, exist_ok=True)

DATA_FILE = INPUT_PROCESSED / "mercedes_sales_processed.csv"

# Helper-Funktion für saubere Dateinamen
def _slugify(text: str) -> str:
    text = (text or "").strip()
    text = re.sub(r"[^\w\s-]", "", text)
    text = re.sub(r"\s+", " ", text)
    return text if text else "Plot"

# Klasse zur Verwaltung und Speicherung der Plots mit fortlaufender Nummerierung
class PlotSaverTree:
    def __init__(self, fig_dir: Path):
        self.fig_dir = fig_dir
        self.counter = self._next_plot_number()

    def _next_plot_number(self) -> int:
        pattern = re.compile(r"^(\d{2,})\s+.*\.png$", re.IGNORECASE)
        nums = []
        for p in self.fig_dir.glob("*.png"):
            m = pattern.match(p.name)
            if m:
                nums.append(int(m.group(1)))
        return (max(nums) + 1) if nums else 1

    def __call__(self, dpi: int = 300):
        fig = plt.gcf()
        if fig is None or len(fig.axes) == 0:
            print("Kein Plot zum Speichern")
            return

        title = plt.gca().get_title() or "plot"
        slug = _slugify(title)
```

```python
        # Prüfen, ob Datei mit diesem Titel existiert
        existing = list(self.fig_dir.glob(f"* {slug}.png"))
        if existing:
            print(f"Übersprungen (Titel existiert bereits): {existing[0].name}")
            return

        filename = f"{self.counter:02d} {slug}.png"
        filepath = self.fig_dir / filename

        fig.tight_layout()
        fig.savefig(filepath, dpi=dpi, bbox_inches="tight")
        print(f"Gespeichert: {filepath.name}")

        # Zähler für den nächsten Aufruf erhöhen
        self.counter += 1

# Einheitliche Größe der Grafiken
plt.rcParams["figure.figsize"] = (8, 5)
plt.rcParams["figure.dpi"] = 100
plt.rcParams["savefig.dpi"] = 120

# Initialisierung der Speicher-Funktion
save_current_plot_tree = PlotSaverTree(FIG_TREE)
```

Datenbasis

In [2]:
```python
# Aufbereitete Daten aus der EDA laden
if not DATA_FILE.exists():
    raise FileNotFoundError(f"Datei nicht gefunden: {DATA_FILE}")

df = pd.read_csv(DATA_FILE)

print("Shape:", df.shape)
display(df.head())
```

```
Shape: (12129513, 7)
```

	Model	Year	Color	Fuel Type	Base Price (USD)	Horsepower	Turbo
0	A-Class	2020	Yellow	Diesel	41265	252	Yes
1	A-Class	2020	Black	Petrol	51023	249	No
2	A-Class	2020	Grey	Petrol	72819	341	Yes
3	A-Class	2020	Black	Petrol	62480	385	Yes
4	A-Class	2020	White	Petrol	35189	337	Yes

- Verwendung der im EDA erstellten `processed.csv`
- 1.212.951 Beobachtungen und 8 Variablen
- Mischung aus numerischen und kategorialen Merkmalen
- Geeignete Datenbasis für die Modellierung

Zielvariable und Features

In [3]:
```
# Zielvariable und Prädiktoren (Features) festlegen
TARGET = "Base Price (USD)"

num_features = ["Year", "Horsepower"]
cat_features = ["Fuel Type", "Turbo", "Model", "Color"]

X = df[num_features + cat_features].copy()
y = df[TARGET].copy()

print("Target:", TARGET)
print("Numerische Features:", num_features)
print("Kategoriale Features:", cat_features)
```

```
Target: Base Price (USD)
Numerische Features: ['Year', 'Horsepower']
Kategoriale Features: ['Fuel Type', 'Turbo', 'Model', 'Color']
```

In [4]:
```
# Kategoriale Variablen für das Modell in numerische Dummy-Variablen umwandeln
X_encoded = pd.get_dummies(X, columns=cat_features, drop_first=True)
```

```
print("Shape nach Encoding:", X_encoded.shape)
display(X_encoded.head())
```

```
Shape nach Encoding: (12129513, 31)
```

	Year	Horsepower	Fuel Type_Electric	Fuel Type_Hybrid	Fuel Type_Petrol	Turbo_Yes	Model_AMG A 45	Model_AMG C 63	Model_AMG E 63	Model_AMG GT
0	2020	252	False	False	False	True	False	False	False	False
1	2020	249	False	False	True	False	False	False	False	False
2	2020	341	False	False	True	True	False	False	False	False
3	2020	385	False	False	True	True	False	False	False	False
4	2020	337	False	False	True	True	False	False	False	False

5 rows × 31 columns

- Zielvariable ist der Basispreis in USD
- Numerische und kategoriale Einflussfaktoren wurden definiert
- Kategoriale Variablen wurden mittels One-Hot-Encoding transformiert
- Nach Encoding stehen 31 Prädiktoren zur Verfügung
- Die Daten sind vollständig modellbereit

Modellierung (Train/Test und Training)

In [5]:
```
# Stichprobe von 1 Mio. ziehen, um Rechenzeit zu sparen, und Daten splitten (80/20)
df_model = df.sample(n=1_000_000, random_state=42)
X = df_model[num_features + cat_features].copy()
y = df_model[TARGET].copy()
X_encoded = pd.get_dummies(X, columns=cat_features, drop_first=True)

X_train, X_test, y_train, y_test = train_test_split(
    X_encoded, y,
    test_size=0.2,
    random_state=42
```

```
)

# Regressionsbaum mit definierten Parametern gegen Overfitting trainieren
tree = DecisionTreeRegressor(
    max_depth=6,
    min_samples_split=2000,
    min_samples_leaf=1000,
    random_state=42
)

tree.fit(X_train, y_train)

print("Train:", X_train.shape, "Test:", X_test.shape)
```

```
Train: (800000, 31) Test: (200000, 31)
```

- Aufgrund der sehr großen Fallzahl (12.129.513 Beobachtungen) wurde eine zufällige Stichprobe von 1.000.000 Fällen gezogen
- Die Ziehung erfolgte reproduzierbar mit festem Random State
- Die Stichprobe ist ausreichend groß, um die zugrunde liegende Datenstruktur stabil abzubilden
- Ziel ist die Reduktion der Rechenzeit ohne methodische Verzerrung

Evaluation

Cross-Validation

In [6]:
```
# Modellstabilität mit 5-facher Cross-Validierung prüfen
cv_scores = cross_val_score(
    tree,
    X_train,
    y_train,
    cv=5,
    scoring="r2"
)

print("R² je Fold:", cv_scores)
print("Durchschnittliches R²:", round(cv_scores.mean() * 100, 1), "%")
print("Standardabweichung:", round(cv_scores.std() * 100, 2), "%")
```

```
R² je Fold: [0.63855253 0.63725232 0.63989281 0.63651124 0.63877279]
Durchschnittliches R²: 63.8 %
Standardabweichung: 0.12 %
```

- Durchschnittliche R^2 beträgt 63,8 %
- Standardabweichung liegt bei lediglich 0,12 %
- Ist über verschiedene Datenaufteilungen hinweg sehr stabil
- Keine Hinweise auf Überanpassung vor

In [7]:
```python
# Vorhersagen treffen und Fehler-Metriken berechnen
y_pred = tree.predict(X_test)

r2 = r2_score(y_test, y_pred)
rmse = np.sqrt(mean_squared_error(y_test, y_pred))
mae = mean_absolute_error(y_test, y_pred)

r2_rounded = round(r2*100, 1)
rmse_rounded = round(rmse, -2)
mae_rounded = round(mae, -2)

print(f"R²: {r2_rounded} %")
print(f"RMSE: {rmse_rounded:,.0f} USD")
print(f"MAE: {mae_rounded:,.0f} USD")
```

```
R²: 63.8 %
RMSE: 40,500 USD
MAE: 29,700 USD
```

- Das Modell erklärt 63,8 % der Varianz des Basispreises
- Der RMSE beträgt 40.500 USD und gewichtet größere Abweichungen stärker
- Der MAE beträgt 29.700 USD und beschreibt die durchschnittliche Prognoseabweichung
- Der Regressionsbaum zeigt eine solide, jedoch nicht vollständige Erklärungskraft

In [8]:
```python
# Einfluss der einzelnen Merkmale auf den Preis extrahieren
einflussfaktoren = pd.DataFrame({
    "Merkmal": X_encoded.columns,
    "Wichtigkeit": tree.feature_importances_
}).sort_values("Wichtigkeit", ascending=False)
```

```python
einflussfaktoren.head(10)
```

Out[8]:

	Merkmal	Wichtigkeit
20	Model_GLS	0.331797
21	Model_S-Class	0.272206
15	Model_G-Class	0.168035
6	Model_AMG A 45	0.082834
1	Horsepower	0.069685
7	Model_AMG C 63	0.068303
0	Year	0.007108
3	Fuel Type_Hybrid	0.000016
4	Fuel Type_Petrol	0.000011
29	Color_White	0.000005

In [9]:

```python
# Die Top 10 Einflussfaktoren als Balkendiagramm visualisieren
top10 = einflussfaktoren.head(10).copy()
top10["Einfluss (%)"] = (top10["Wichtigkeit"] * 100).round(1)

plt.figure(figsize=(8,6))
bars = plt.barh(top10["Merkmal"], top10["Einfluss (%)"])

plt.gca().invert_yaxis()
plt.title("Relative Merkmale - Top 10")
plt.xlabel("Einflussanteil (%)")
plt.xlim(0, 40) # bis 40% für bessere Darstellung

save_current_plot_tree()

# Prozentwerte an die Balken anfügen
for bar in bars:
    width = bar.get_width()
    plt.text(
```

```
        width + 0.5,
        bar.get_y() + bar.get_height()/2,
        f"{width:.1f} %",
        va="center"
    )

plt.tight_layout()
plt.show()
```

```
Gespeichert: 01 Relative Merkmale - Top 10.png
```

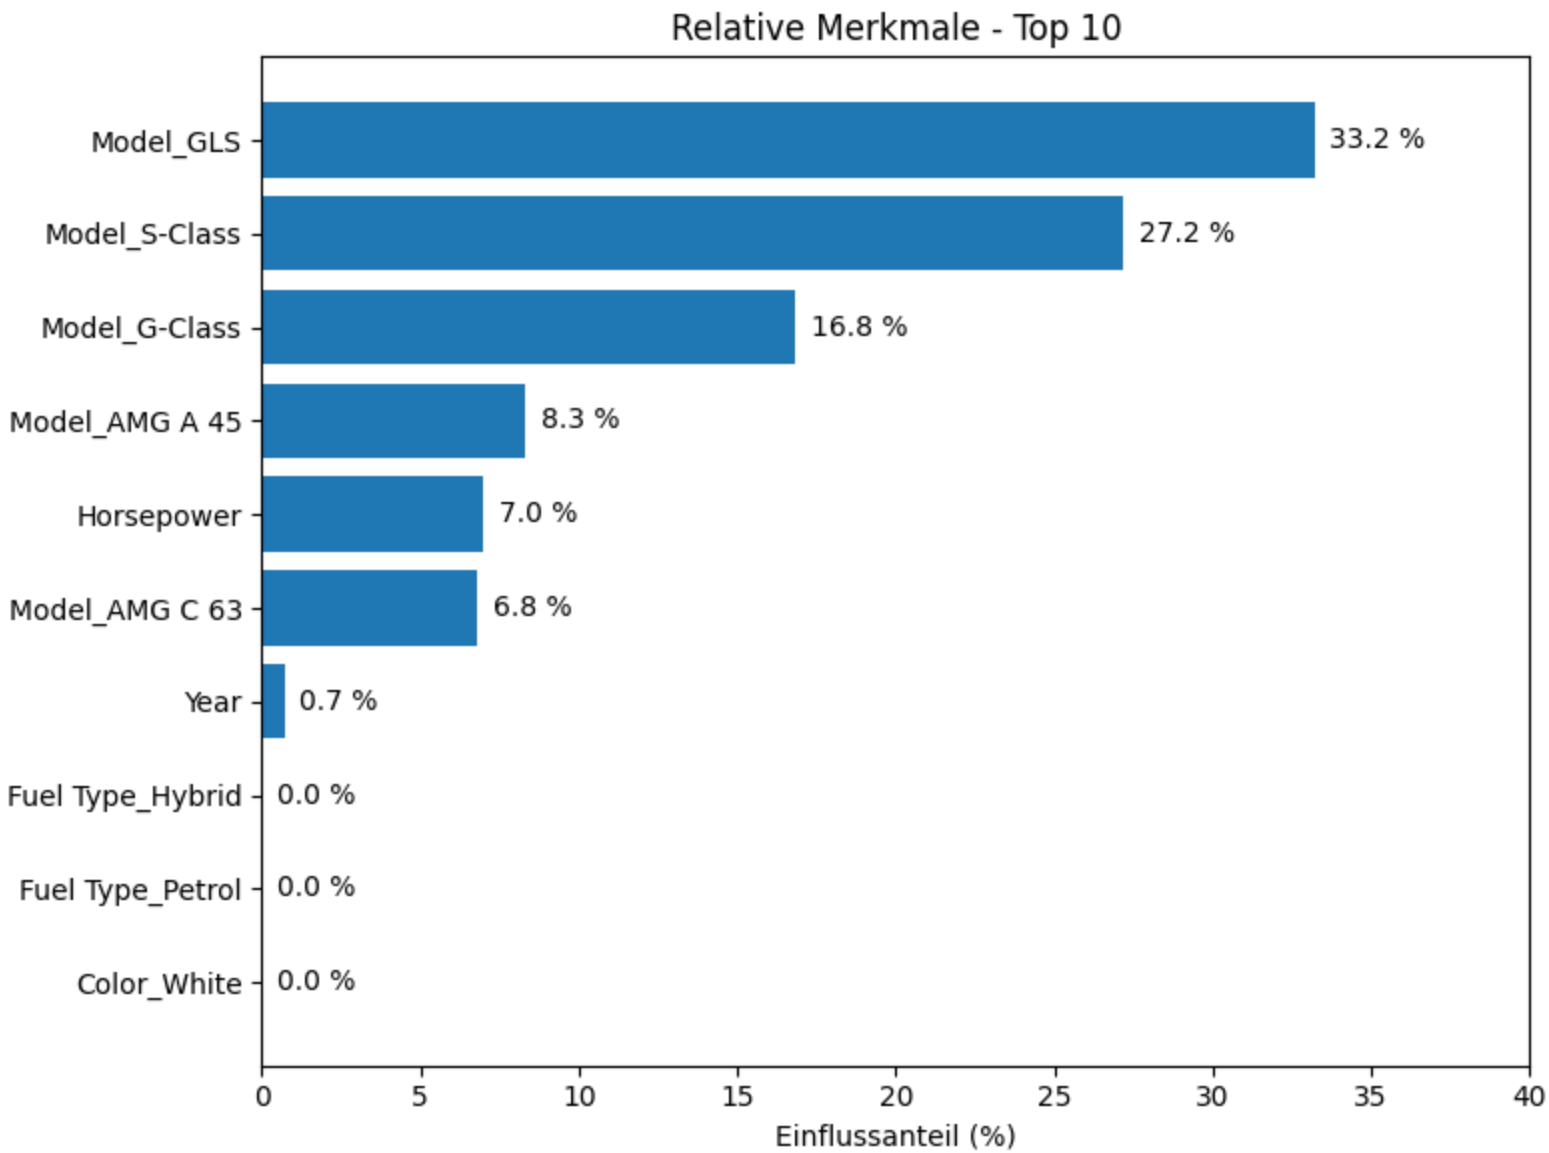

- Modellzugehörigkeit dominiert Preisbestimmung (GLS, S-Klasse, G-Klasse)
- Motorleistung -> moderaten Einfluss
- Baujahr -> geringe Rolle
- Kraftstoffart / Farbe tragen kaum zur Preisvariation bei

- Basispreis primär durch Fahrzeugklasse bestimmt

In [10]:
```
plt.figure(figsize=(24, 12))
plot_tree(
    tree,
    feature_names=X_encoded.columns,
    filled=True,
    rounded=True,
    max_depth=3,          # -> 3 Ebene zur besseren Übersicht
    impurity=False,
    fontsize=8
)
plt.title("Regressionsbaum (Ausschnitt bis Tiefe 3)")

save_current_plot_tree()

plt.tight_layout()
plt.show()
```

```
Gespeichert: 02 Regressionsbaum Ausschnitt bis Tiefe 3.png
```

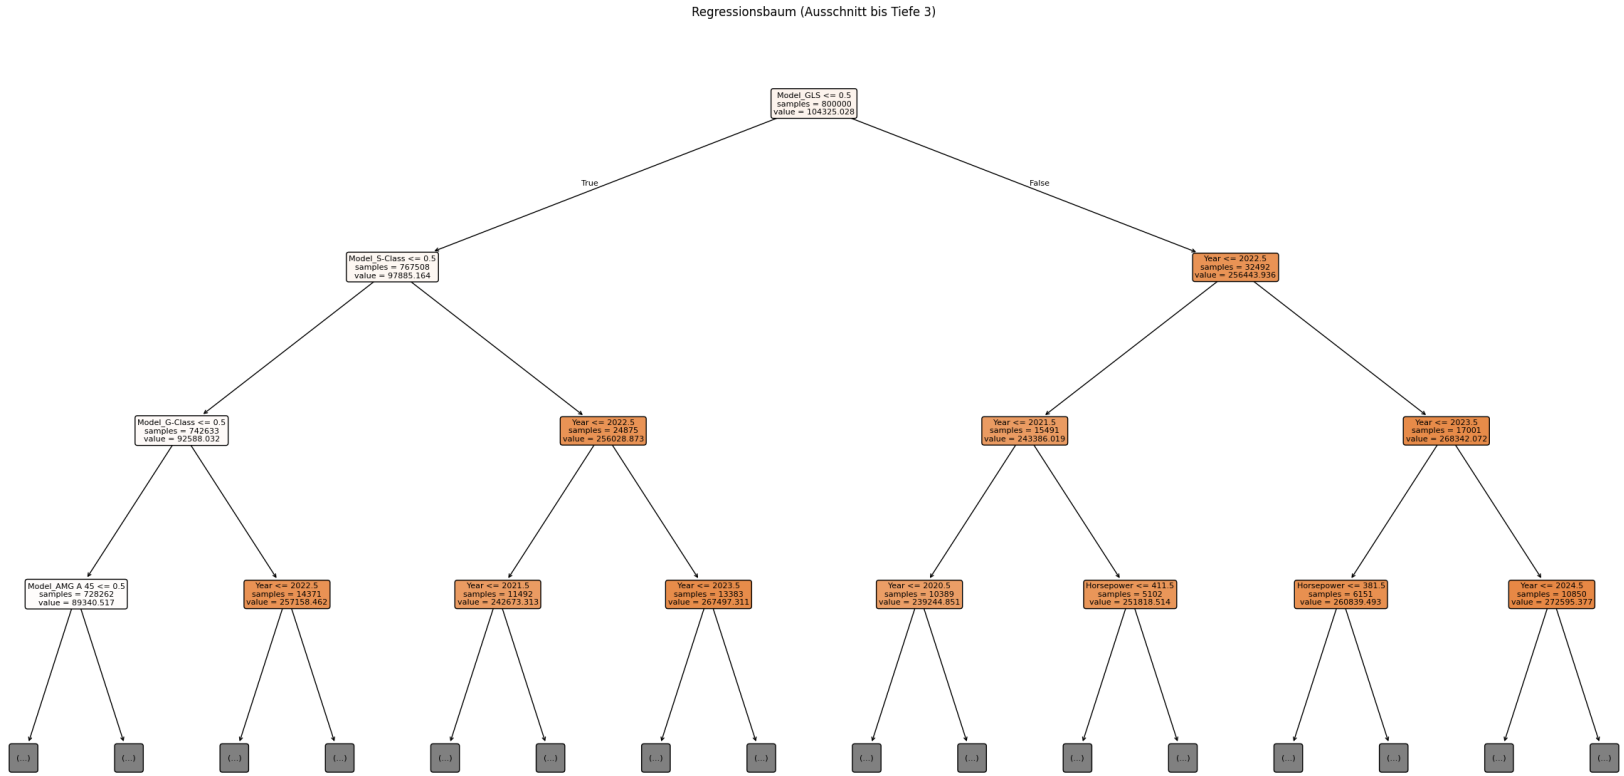

- Erster Split erfolgt nach dem Modell (GLS) → stärkster Preiseinfluss
- Weitere Splits erfolgen nach S-Klasse und G-Klasse
- In späteren Ebenen gewinnt das Baujahr an Bedeutung
- Motorleistung beeinflusst den Preis erst auf tieferen Ebenen
- Die Preisstruktur wird primär durch die Fahrzeugklasse bestimmt

In [11]:
```
# Streudiagramm zur Kontrolle: Prognostizierte vs. Tatsächliche Preise (10k Stichprobe)
idx = np.random.RandomState(42).choice(len(y_test), size=10000, replace=False)

plt.figure(figsize=(6,6))
plt.scatter(y_test.iloc[idx], y_pred[idx], alpha=0.3)

# Ideallinie einzeichnen
```

```python
plt.plot(
    [y_test.min(), y_test.max()],
    [y_test.min(), y_test.max()],
    linewidth=1
)

plt.title("Prognose vs. Realität (Stichprobe: 10.000)")
plt.xlabel("Tatsächlicher Basispreis (USD)")
plt.ylabel("Prognostizierter Basispreis (USD)")
plt.tight_layout()
save_current_plot_tree()
plt.show()
```

```
Gespeichert: 03 Prognose vs Realität Stichprobe 10000.png
```

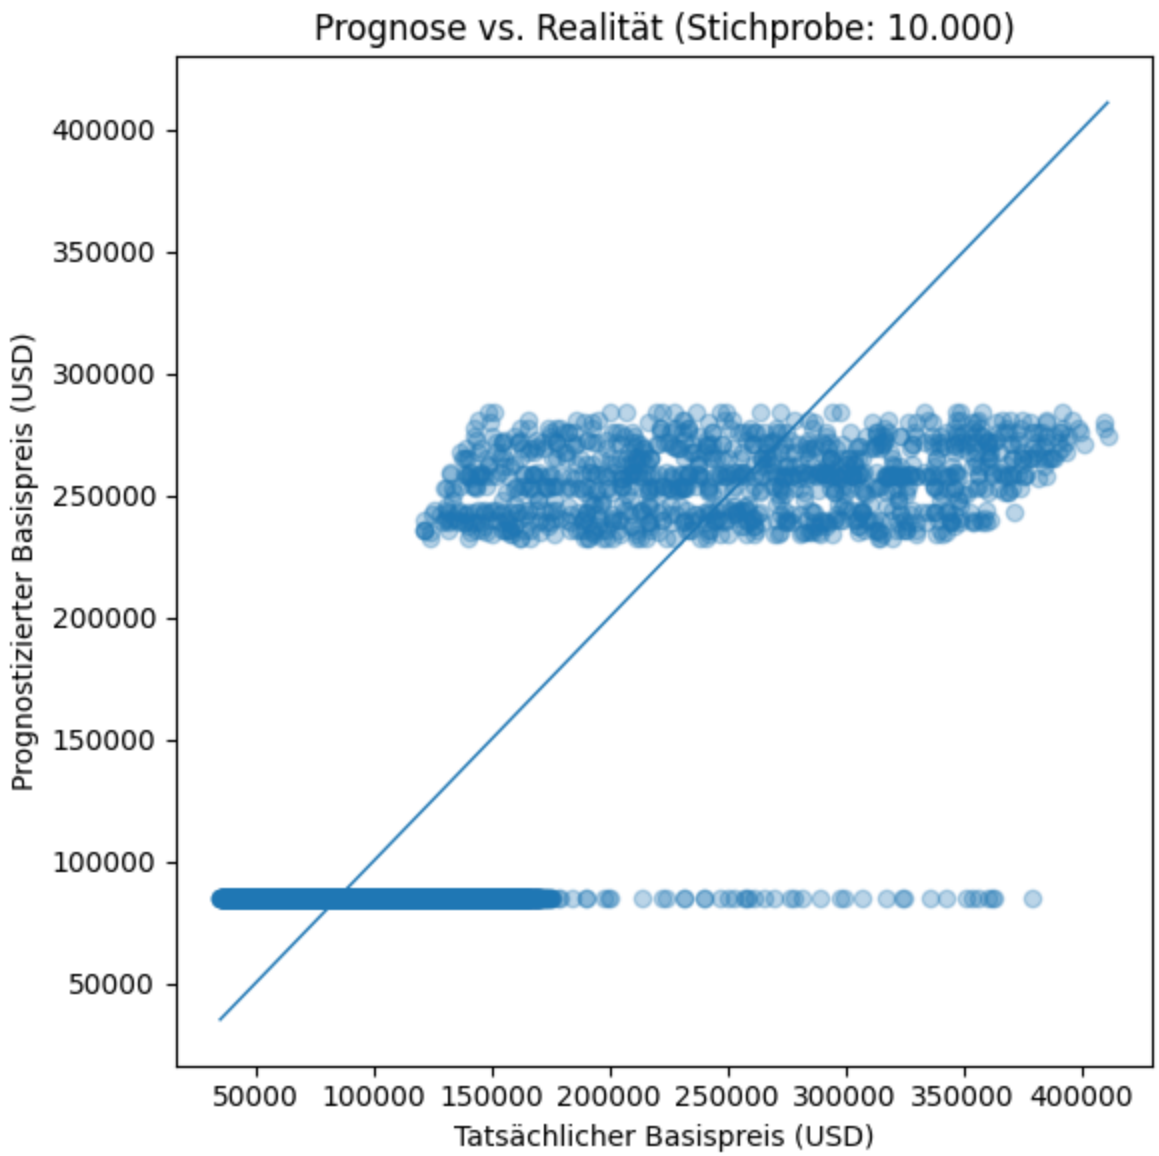
Prognose vs. Realität (Stichprobe: 10.000)
Prognostizierter Basispreis (USD)
400000
350000
300000
250000
200000
150000
100000
50000
50000
100000
150000
200000
250000
300000
350000
400000
Tatsächlicher Basispreis (USD)

- Diagonale = Perfekte Vorhersage
- Treppenmuster: Typisch für Regressionsbäume (bilden diskrete Preis-Cluster)
- Niedrige/mittlere Preise: Sehr stabile Prognose (Punkte nahe der Diagonalen)
- Hochpreissegment: Starke Streuung und Tendenz zur Unterschätzung

Gesamtwertung

- Modellklasse ist der wichtigste Preisfaktor
- Motorleistung wirkt als sekundärer technischer Treiber
- Regressionsbaum erklärt rund 64 % der Preisvarianz
- Preisstruktur folgt klar segmentierten Fahrzeugklassen